Université de la Manouba

École Supérieure d'Économie Numérique

Rapport de mimi projet

Sujet

Conception d'une Application d'Aide à la Décision pour le Suivi des Activités Commerciales

Élaboré par : **Mohamed ali Jabri**
&
Amine Nuisser

Année Universitaire : 2024/2025

Sommaire

Partie 1 : Intégration des données : 3
I. Prétraitement des données 3
1. Fichier 1 : Vente (vente2015_2016.xlsx) 3
2. Fichier 2 : Stations (Stations.xlsx) 5
3. Fichier 3 : Clients (codification clients.xlsx) 6
4. Connexions aux bases de données 9
a. Connexion SQL Server 9
b. Connexion SSIS 11
5. Développement du système ETL 14
II. Extraction des données 15
1. Deux tâche d'exécution de requêtes SQL 15
2. Tâche de flux de données 16
III. Transformation et chargement des données 19
1. Alimentation des tables de dimensions 19
2. Alimentation de la table de fait 22
Partie2 : Solution BI 24

Liste des figures

Figure 1 : Code de prétraitement de fichier vente. 4
Figure 2 : Code de prétraitement de fichier santions 6
Figure 3 : Codes de prétraitement de fichier clients. 8
Figure 4 : Codes de prétraitement de fichier clients. 9
Figure 5 : Authentification SQL Server. 10
Figure 6 : Création BI Commerciale ODS. 10
Figure 7 : Création BI Commerciale DWH. 11
Figure 8 : Gestionnaire de connexion SSIS. 12
Figure 9 : Gestionnaire de connexion BI Commerciale ODS. 12
Figure 10 : Gestionnaire de connexion BI Commerciale DWH. 13
Figure 11 : Gestionnaire de connexion EXCEL. 14
Figure 12 : Lancement d'un nouveau projet. 14
Figure 13 : Flux de contrôle du vente_ODS. 15
Figure 14 : Tâche d'exécution de requêtes SQL (vide). 16
Figure 15 : Chargement de la table Vente_ODS. 16
Figure 16 : Visualisation de la table Vente_ODS. 17
Figure 17 : Client ODS 17
Figure 18 : Categorie_ODS. 18
Figure 19 : Loc_gouvernorat_ODS. 18
Figure 20 : Diagramme d'activité de chargement des dimensions. 19
Figure 21 : Alimentation de la table DIM_Client. 20
Figure 22 : Alimentation de la table DIM_PRODUIT. 21
Figure 23 : Alimentation de la table DIM_CUSTOMER. 21
Figure 24 : Diagramme d'activité du chargement de la table de fait 22
Figure 25 : Diagramme d'activité du chargement de la table de fait. 23
Figure 26 : Page d'accueil. 24
Figure 27 : Reporting des vente par client. 25
Figure 28 : Reporting des vente par Produit. 26
Figure 29 : Reporting des vente par date. 27

Partie 1 : Intégration des données :

I. Prétraitement des données

Afin de garantir la qualité et la cohérence des données utilisées dans le processus ETL, un prétraitement a été effectué sur les trois principaux fichiers sources : **vente**, **stations** et **clients**.

1. Fichier 1 : Vente (vente2015_2016.xlsx)

Input : Deux feuilles représentant les ventes des années **2015** et **2016**.

Opérations :

- ✓ Nettoyage des lignes vides et des doublons.
- ✓ Uniformisation des colonnes (QTEPRD, MNTHT, etc.).
- ✓ Standardisation des formats texte et numérique.
- ✓ Création de la colonne **PERIODE** au format AAAAMM.
- ✓ Suppression des lignes incomplètes.
- ✓ Fusion des deux années en une seule table.

Output : Fichier consolidé vente_pretraite.xlsx, prêt pour l'intégration dans l'entrepôt de données.

Comme présenté dans la figure 1 suivante.

```python
import pandas as pd

# Charger le fichier Excel avec plusieurs feuilles
vente_xls = pd.read_excel("/content/vente2015_2016.xlsx", sheet_name=None)

# Fonction de prétraitement
def clean_vente_data(df, year):
    df = df.dropna(how='all')

    # Renommer les colonnes
    df = df.rename(columns={
        'SUM(QTEPRD)': 'QTEPRD',
        'SUM(MNTHT)': 'MNTHT'
    })

    # Nettoyer les chaînes
    for col in df.select_dtypes(include='object').columns:
        df[col] = df[col].astype(str).str.strip().str.upper()

    # Créer PERIODE = AAAAMM
    mois = pd.to_numeric(df['MOIS'], errors='coerce').fillna(1).astype(int).clip(1, 12)
    df['PERIODE'] = year * 100 + mois

    # Nettoyage des types numériques
    df['QTEPRD'] = pd.to_numeric(df['QTEPRD'], errors='coerce')
    df['MNTHT'] = pd.to_numeric(df['MNTHT'], errors='coerce')

    # Supprimer les lignes critiques incomplètes
    df = df.dropna(subset=['PERIODE', 'NUMCPT', 'CODPRD', 'TYPOPE'])

    # Ordre des colonnes orienté métier
    colonnes_ordre = [
        'NUMCPT', 'NOMCLI',
        'CODPRD', 'LIBPRD', 'CATPRD', 'CODEMB',
        'QTEPRD', 'MNTHT', 'TYPOPE','PERIODE',
        'CODAME', 'LIBAME',
        'CODDPO', 'NOMDPO',
        'CODGVR', 'LIBGVR',
        'CODLOC', 'LIBLOC'
    ]

    return df[[col for col in colonnes_ordre if col in df.columns]]

# Nettoyer les deux années
vente_2015 = clean_vente_data(vente_xls['2015'], 2015)
vente_2016 = clean_vente_data(vente_xls['2016'], 2016)

# Fusionner
vente_finale = pd.concat([vente_2015, vente_2016], ignore_index=True)

# Sauvegarder
vente_finale.to_excel("vente_pretraite.xlsx", index=False)
```

Figure 1: Code de prétraitement de fichier vente.

2. **Fichier 2 : Stations (Stations.xlsx)**

Input : Deux feuilles : **categorie** (catégories de produits) et **localite_gouvernorat** (localisations géographiques).

Opérations :

- ✓ Nettoyage des colonnes (suppression des colonnes inutiles, correction des noms).
- ✓ Suppression des lignes vides et des doublons.
- ✓ Harmonisation des textes (majuscules, suppression des espaces).
- ✓ Renommage des colonnes pour clarifier l'information (CATEGORIE_CODE, CODE_LOCALITE, etc.).

Output : Deux fichiers propres :

- ❖ stations_categorie.xlsx,
- ❖ stations_localite_gouvernorat.xlsx.

la figure 2 présenté Code de prétraitement de fichier stations

```python
import pandas as pd

# Fonction de nettoyage générique
def clean_station_df(df, key_cols=None):
    df.columns = df.columns.str.strip().str.upper()
    df = df.loc[:, ~df.columns.str.startswith("UNNAMED")]
    df = df.dropna(how='all')
    for col in df.select_dtypes(include='object').columns:
        df[col] = df[col].str.strip().str.upper()
    df = df.drop_duplicates()
    if key_cols:
        df = df.dropna(subset=[col.strip().upper() for col in key_cols])
    return df

# Chargement du fichier
stations_file = "/content/Stations.xlsx"
stations_sheets = pd.read_excel(stations_file, sheet_name=None)

# --- Feuille 'categorie'
df_categorie = clean_station_df(stations_sheets["categorie"], key_cols=["CODCAT", "LIBCAT"])
df_categorie = df_categorie.rename(columns={
    "CODCAT": "CATEGORIE_CODE",
    "LIBCAT": "CATEGORIE_LIBELLE"
})

# --- Feuille 'localite_gouvernorat'
df_localite = clean_station_df(stations_sheets["localite_gouvernorat"], key_cols=["CODGVR", "LIBLOC"])
df_localite = df_localite.rename(columns={
    "CODGVR": "CODE_GOUVERNORAT",
    "CODLOC": "CODE_LOCALITE",
    "LIBGVR": "NOM_GOUVERNORAT",
    "LIBLOC": "NOM_LOCALITE"
})

# Sauvegarde
df_categorie.to_excel("stations_categorie.xlsx", index=False)
df_localite.to_excel("stations_localite_gouvernorat.xlsx", index=False)
```

Figure 2 : Code de prétraitement de fichier santions

3. Fichier 3 : Clients (codification clients.xlsx)

Input : Quatre feuilles : LISTECLIENTS, LISTECLIENTSGAZ, LISTECLIENTSJET, et LISTESTATION.

Opérations :

- ✓ Nettoyage des colonnes et des données.
- ✓ Normalisation des noms de colonnes (NUMCPT, NOMCLI, etc.).
- ✓ Ajout d'une colonne **TYPE_CLIENT** pour identifier le type de client (GÉNÉRAL, GAZ, JET, STATION).

- ✓ Fusion des quatre feuilles en une table unique.
- ✓ Sélection des colonnes importantes pour l'analyse.

Output : Fichier consolidé clients_pretraite.xlsx.

Les figures 3, 4 présenté Codes de prétraitement de fichier clients.

```python
import pandas as pd

CLIENTS_FILE = "/content/codification clients.xlsx"

# Lecture de toutes les feuilles sauf LISTESTATION
clients_sheets = pd.read_excel(CLIENTS_FILE, sheet_name=None)

# Fonction de nettoyage générique pour feuilles standards
def clean_df(df, key_cols):
    # Normaliser noms de colonnes
    df.columns = df.columns.str.strip().str.upper()
    # Supprimer colonnes Unnamed
    df = df.loc[:, ~df.columns.str.startswith("UNNAMED")]
    # Supprimer lignes vides
    df = df.dropna(how='all')
    # Nettoyage des valeurs textuelles
    for col in df.select_dtypes(include='object').columns:
        df[col] = df[col].str.strip().str.upper()
    # Supprimer doublons
    df = df.drop_duplicates()
    # Supprimer lignes où clés manquantes
    df = df.dropna(subset=[col.strip().upper() for col in key_cols])
    return df

# Traitement de LISTECLIENTS
df_clients = clean_df(clients_sheets["LISTECLIENTS"], key_cols=["COMPTE", "CLIENT"])
df_clients = df_clients.rename(columns={
    "COMPTE":   "NUMCPT",
    "CLIENT":   "NOMCLI",
    "SECTEURS CLIENTS": "SECTEUR_CLIENT",
    "CONSOLIDATION CLIENT": "CONSOLIDATION_CLIENT",
    "GOUVERNORAT": "CODGVR",
    "AME":       "CODAME"
})
df_clients["TYPE_CLIENT"] = "GENERAL"

# Traitement de LISTECLIENTSGAZ
df_gaz = clean_df(clients_sheets["LISTECLIENTSGAZ"], key_cols=["COMPTE", "CLIENT"])
df_gaz = df_gaz.rename(columns={
    "COMPTE":   "NUMCPT",
    "CLIENT":   "NOMCLI",
    "SECTEURS CLIENTS": "SECTEUR_CLIENT",
    "GOUVERNORAT": "CODGVR",
    "CATEGORIE": "CATEGORIE_GAZ"
})
df_gaz["TYPE_CLIENT"] = "GAZ"

# Traitement de LISTECLIENTSJET
df_jet = clean_df(clients_sheets["LISTECLIENTSJET"], key_cols=["COMPTE", "CLIENT"])
df_jet =
```

Figure 3 : Codes de prétraitement de fichier clients.

```python
# Traitement de LISTESTATION (header à la ligne 1)
df_station = pd.read_excel(CLIENTS_FILE, sheet_name="LISTESTATION", header=1)
# Nettoyage similaire
df_station.columns = df_station.columns.str.strip().str.upper()
df_station = df_station.dropna(how='all')
df_station = df_station.rename(columns={
    "CODE":    "NUMCPT",
    "STATION": "NOMCLI",
    "GOUVERNORAT": "CODGVR",
    "SERVICE": "SERVICE_TYPE"
})
#On peut garder SERVICE_TYPE ou le renommer/typele
df_station["TYPE_CLIENT"] = "STATION"
df_station = df_station.dropna(subset=["NUMCPT", "NOMCLI"])

#Concaténer toutes les feuilles traitées
clients_master = pd.concat(
    [df_clients, df_gaz, df_jet, df_station],
    ignore_index=True,
    sort=False
)

#Sélection et ordre final des colonnes
final_columns = [
    "NUMCPT", "NOMCLI", "TYPE_CLIENT",
    "SECTEUR_CLIENT", "CONSOLIDATION_CLIENT",
    "CODAME", "CODGVR", "SERVICE_TYPE"
]
clients_master = clients_master[[c for c in final_columns if c in clients_master.columns]]

#Sauvegarde
clients_master.to_excel("clients_pretraite.xlsx", index=False)
```

Figure 4 : Codes de prétraitement de fichier clients.

4. Connexions aux bases de données

Pour notre mini projet, nous utiliser Microsoft SQL Server, qui utilise Langage SQL (Structured Query Language). Cet outil est considéré comme l'un des plus utilisés fournir aux utilisateurs un contrôle, un tri et une mise à jour plus efficaces, et Autres fonctions, base de données.

a. Connexion SQL Server

Pour se connecter aux bases de données au sein de Microsoft SQL Server Management, nous créons une instance locale avec une authentification sécurisée qui garantit la confidentialité des données.

La figure 5 présente authentification SQL Server.

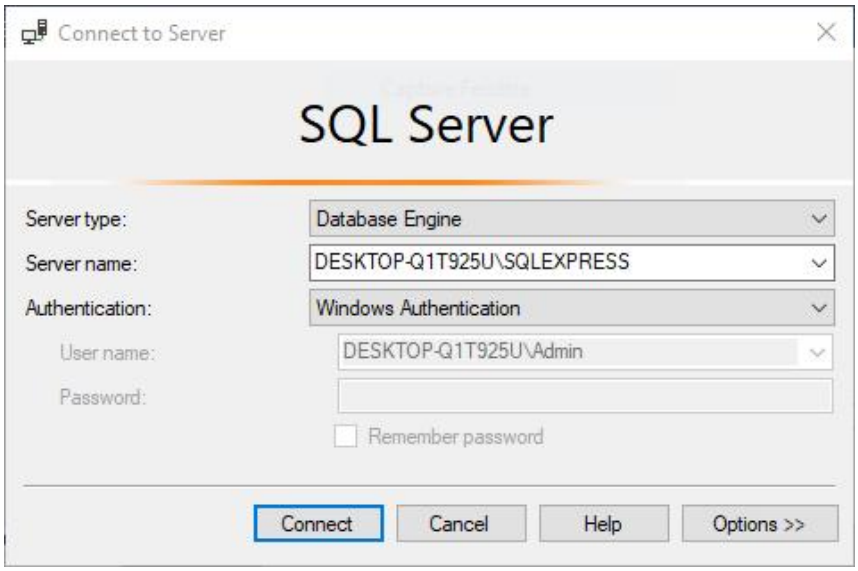

Figure 5 : Authentification SQL Server.

Ensuite, nous créons deux bases de données : BI Commerciale ODS,BI Commerciale DWH.

La base de données BI Commerciale ODS stocke les données de systèmes sources hétérogènes ou elles seront préparées, nettoyez et servez dans BI Commerciale DWH.

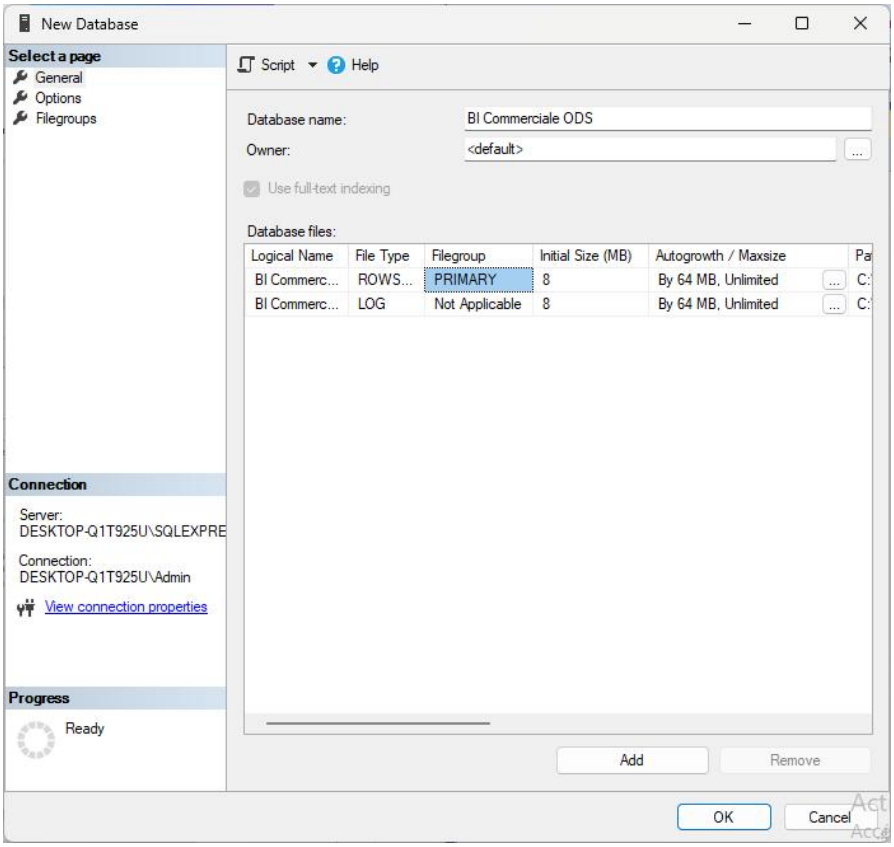

Figure 6 : Création BI Commerciale ODS.

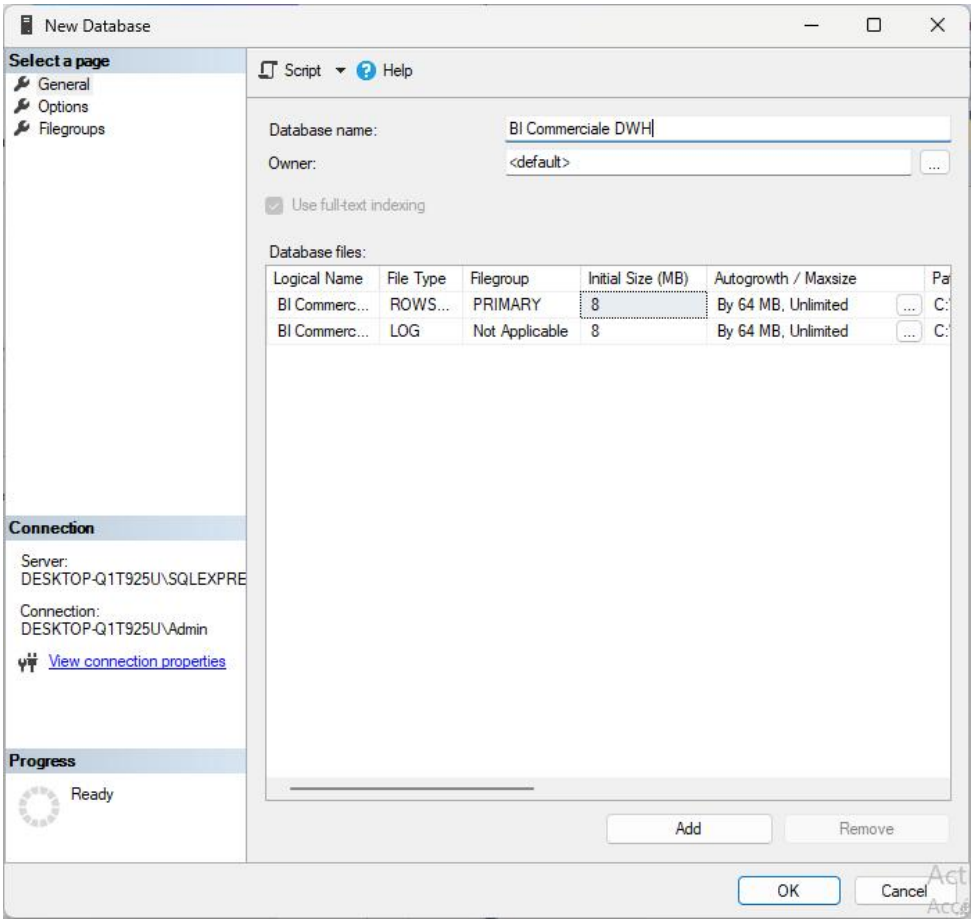

Figure 7 : Création BI Commerciale DWH.

b. Connexion SSIS

Pour accomplir les tâches d'intégration, nous exploitons les capacités de l'outil **SQL Server Integration Services (SSIS)**. En fait, cette dernière conçue comme un outil d'entreposage de données (DW) rapide et flexible pour réaliser des intégrations de données hautes performances et nous donne le privilège d'établir de nombreux types de connexions.

Dans notre exemple, nous utilisons deux types de gestionnaires de connexions, dont EXCEL et OLEDB, comme le montre la figure 8.

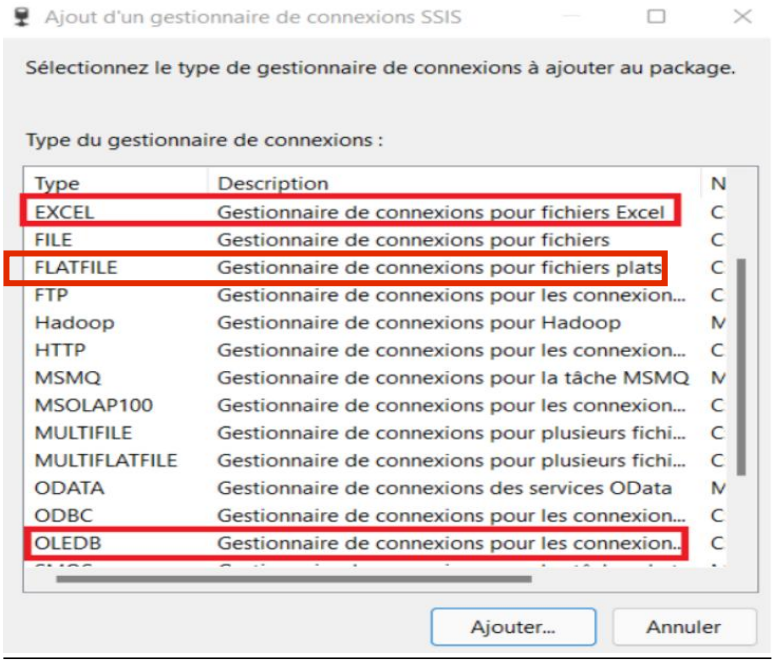

Figure 8 : Gestionnaire de connexion SSIS.

Pour établir une connexion à la base de données nous avons spécifiquement utiliser :

- <u>Gestionnaires de connexion **OLEDB**</u>

Ils nous permettent spécifiquement de nous connecter aux bases de données source et cibleBI Commerciale ODS,BI Commerciale DWH. .

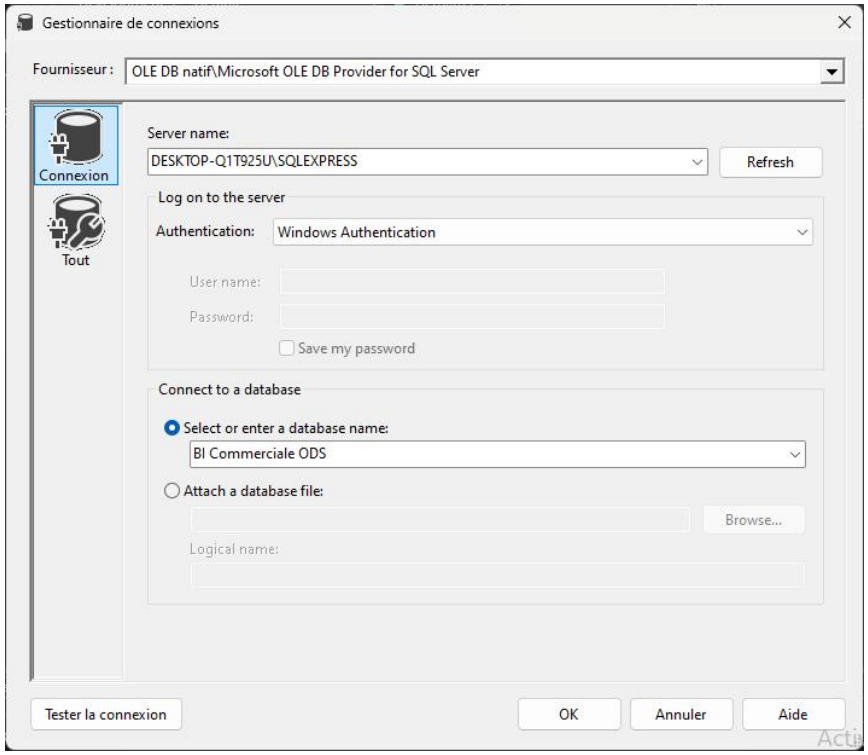

Figure 9 : Gestionnaire de connexion BI Commerciale ODS.

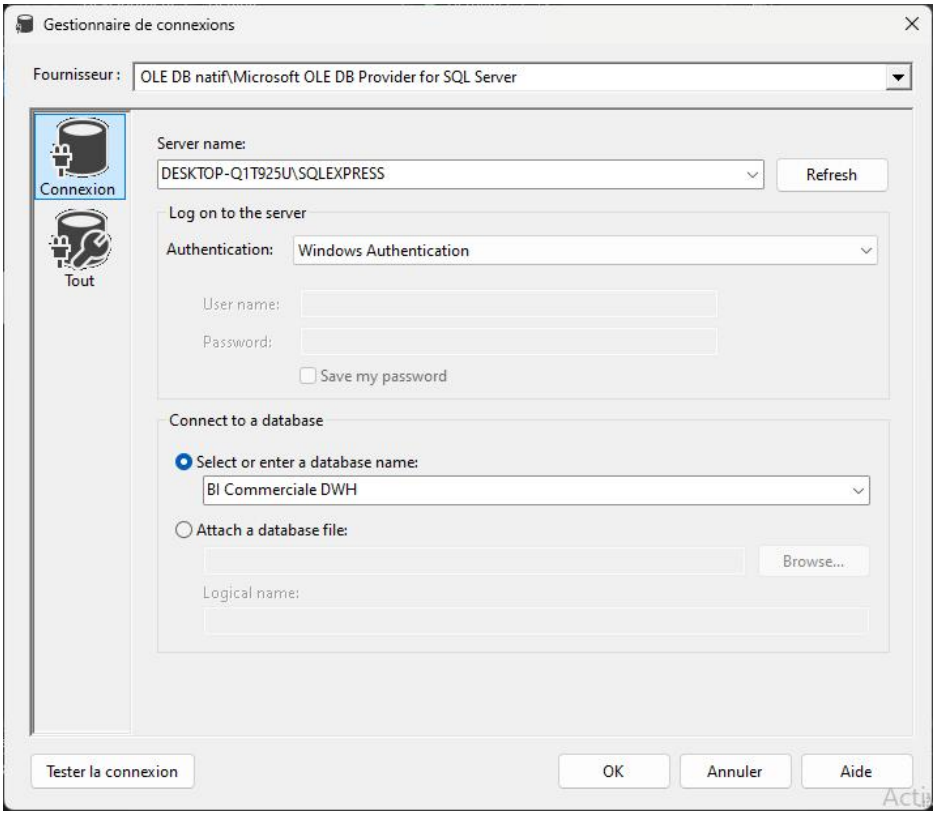

Figure 10 : Gestionnaire de connexion BI Commerciale DWH.

❖ Gestion de connexion **EXCEL**

Il nous permet de nous connecter au ficher des donnes.

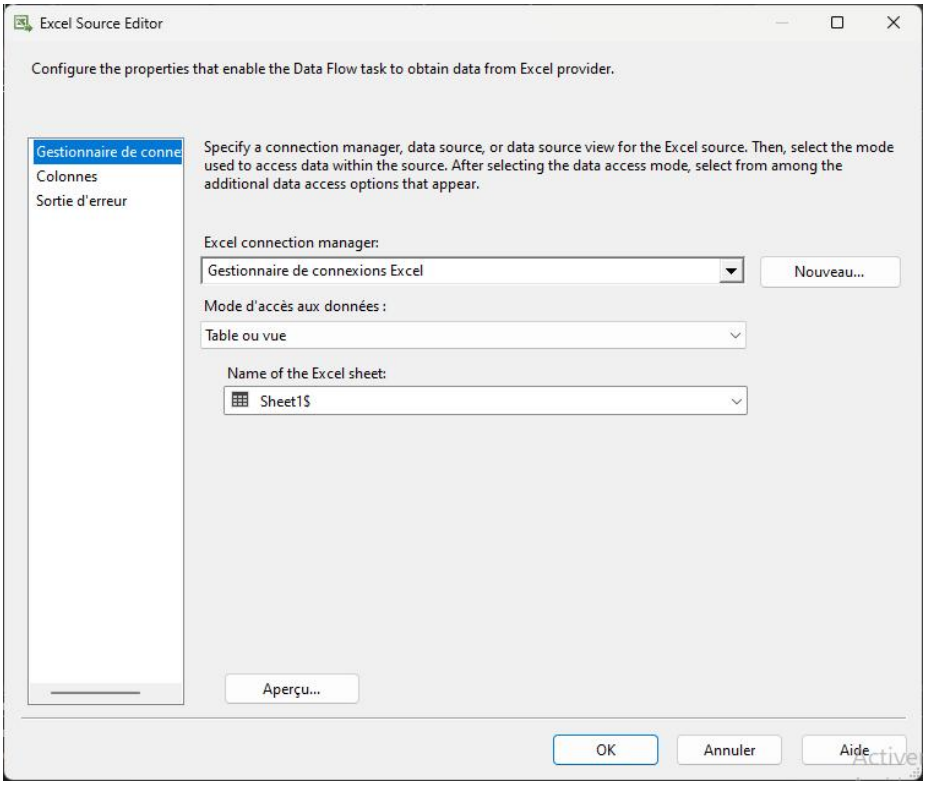

Figure 11 : Gestionnaire de connexion EXCEL.

5. Développement du système ETL

Pour commencer la phase de développement de la solution, nous démarrons d'abord un nouveau projet utilisant le produit Microsoft Visual Studio.

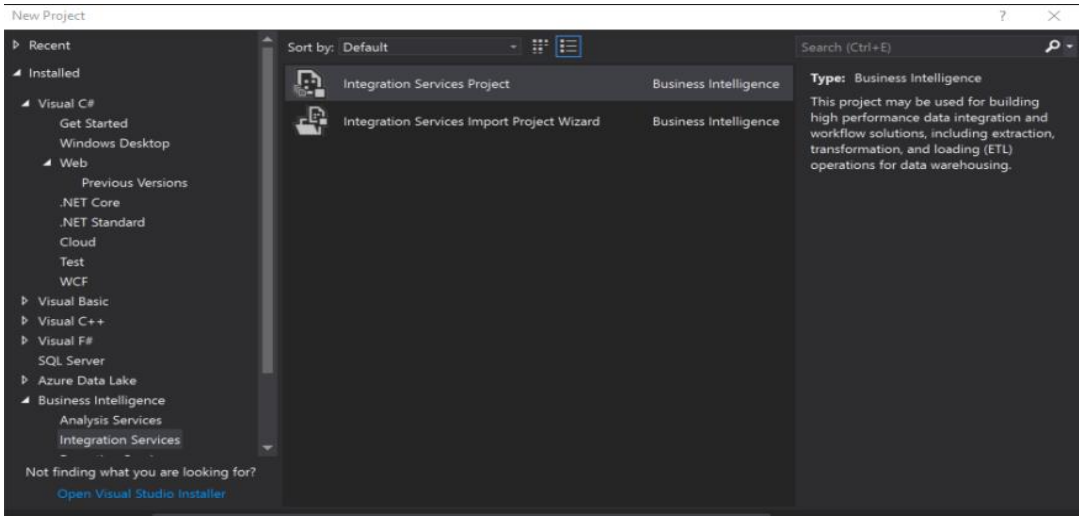

Figure 12 : Lancement d'un nouveau projet.

Nous créons des packages SSIS qui est inclus avec la plupart des versions de SQL Server il nous permet de déplacer des données d'un endroit à un autre et également de modifier les données avant de les

déplacer, chacun avec des tâches différentes, et chaque package avec des tâches différentes. La tâche se compose de plusieurs composants qui nous permettent d'assurer le bon développement du système ETL.

II. Extraction des données

Au niveau du package Vente_ODS, nous utilisons le flux de contrôle suivant pour extraire les données source et les charger dans la zone de préparation.

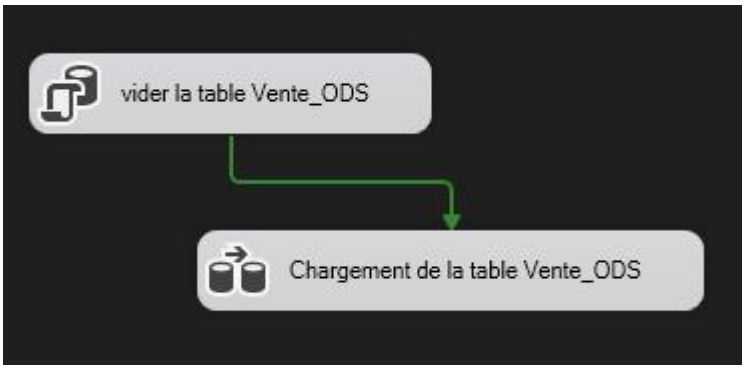

Figure 13 : Flux de contrôle du vente_ODS.

Le flux de contrôle de Vente_ODS est constitué des éléments décrits par la suite.

1. Deux tâche d'exécution de requêtes SQL

Nous avons deux tâches de flux de données pour extraire les données de la table **Vente_Excel**, ce qui nous permet d'obtenir les données pour les récupérez dans **Vente_ODS** et récupérez-les dans la base de données **BI Commercial ODS.** Ci-dessous, nous montrons un exemple d'extraction de données d'une tâche de table **Vente** elle peut être résumée en deux étapes.

À chaque exécution, il est important de s'assurer que les données déjà présentes dans la table sont supprimées pour éviter la duplication. Pour cela nous utilisons la commande **TRUNCATE.**

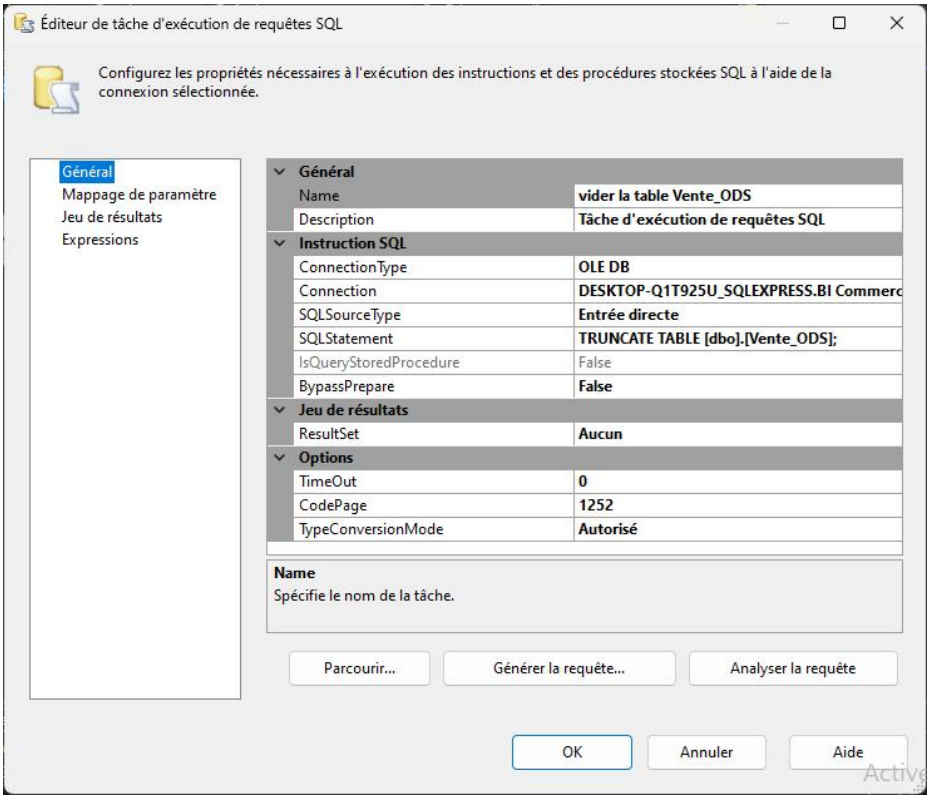

Figure 14 : Tâche d'exécution de requêtes SQL (vide).

2. Tâche de flux de données

Pour la tâche de flux de données qui est dédié pour le chargement de la table Vente_ODS .

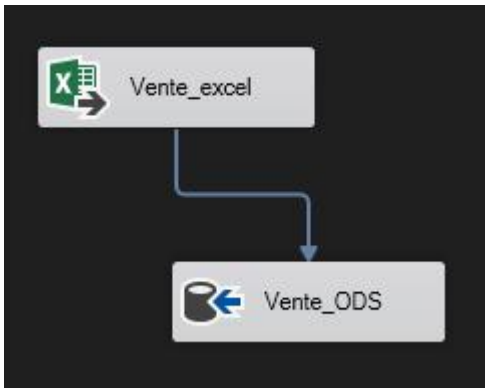

Figure 15 : Chargement de la table Vente_ODS.

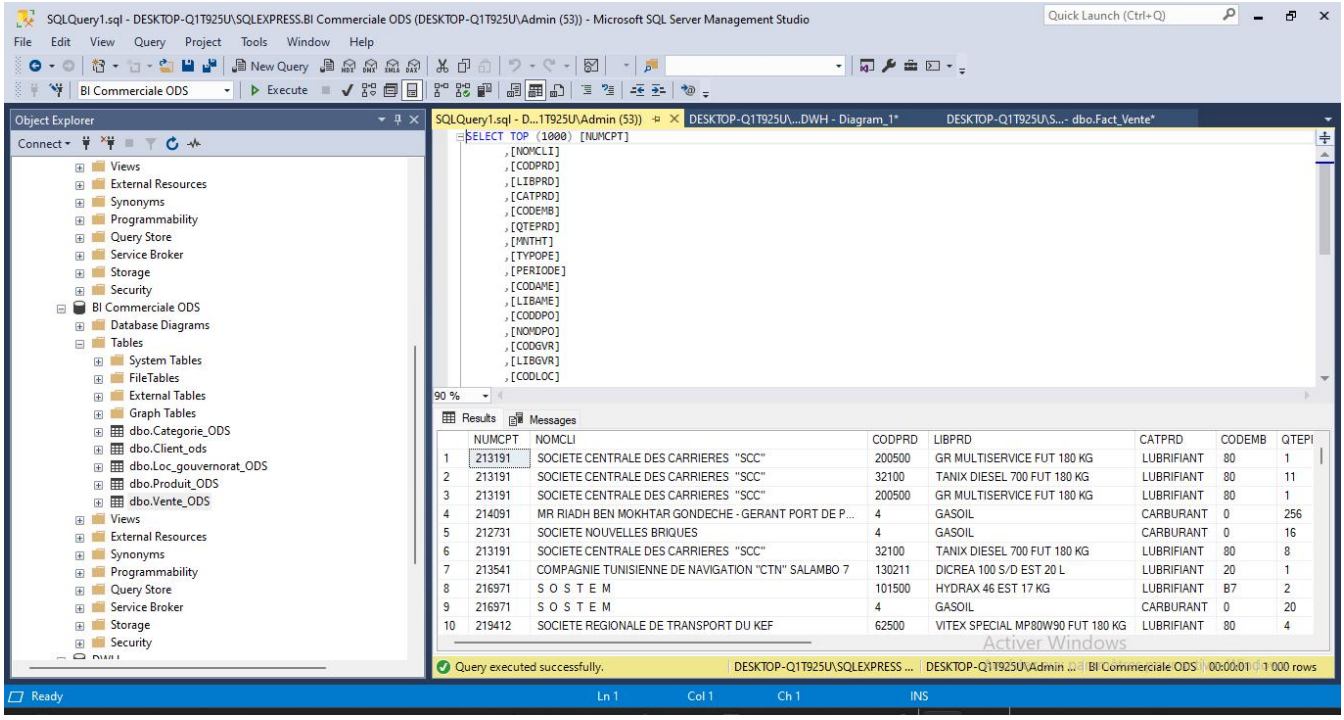

Figure 16 : Visualisation de la table Vente_ODS.

- *<u>Client ODS</u>*

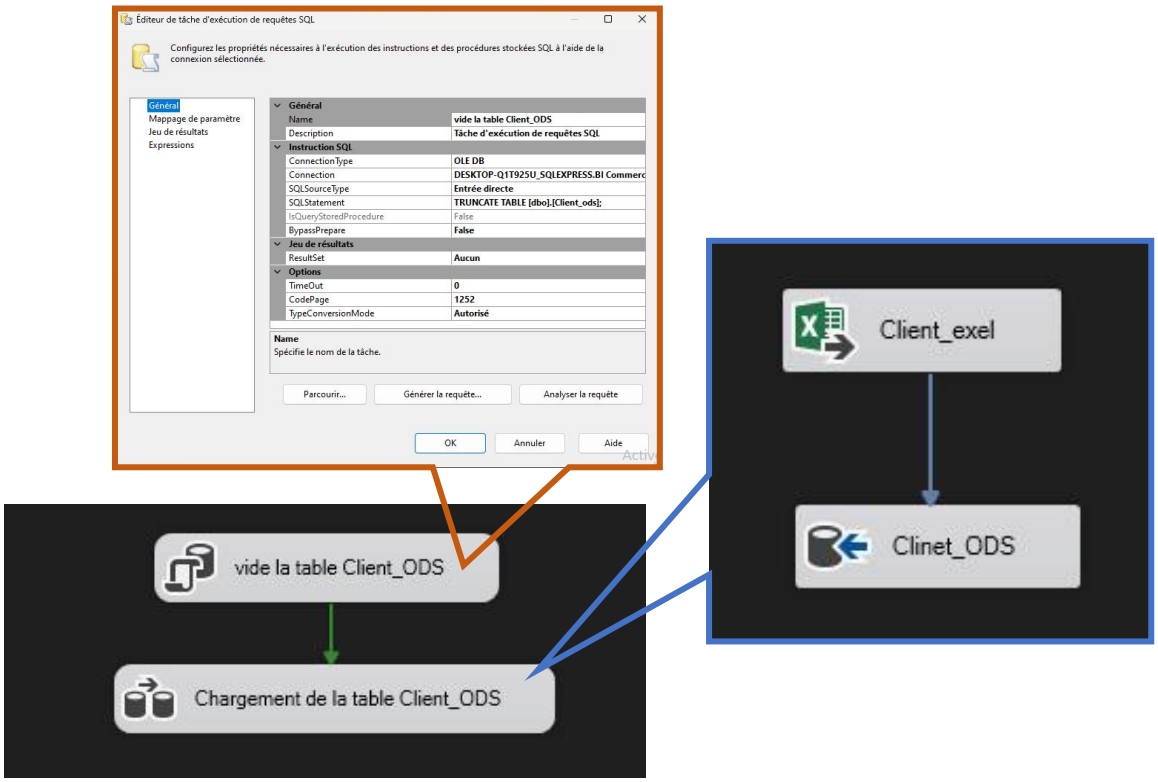

Figure 17 : Client ODS

- *Categorie_ODS :*

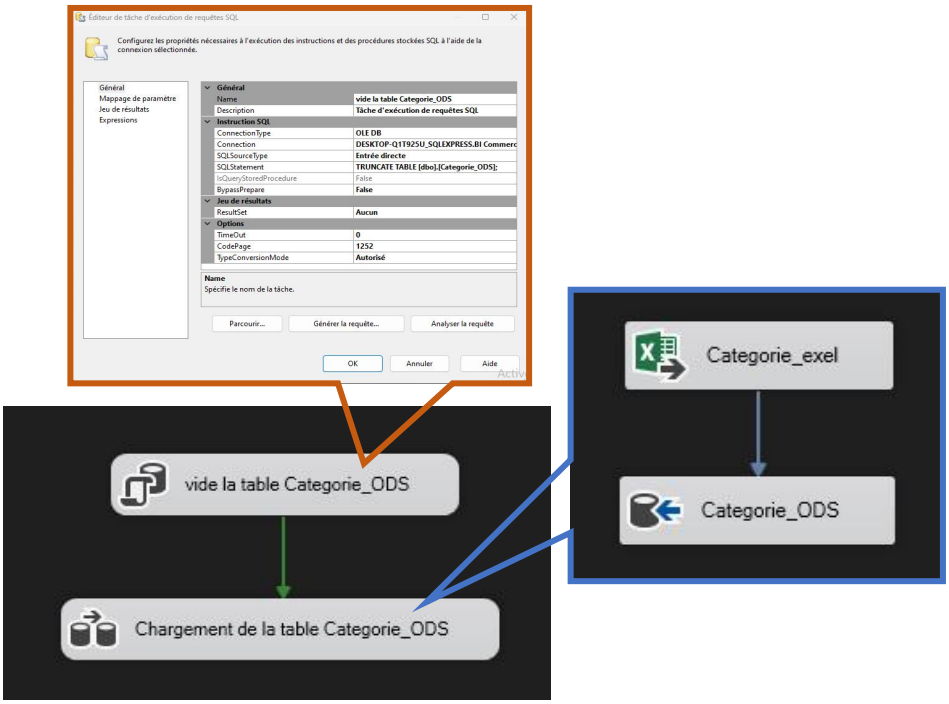

Figure 18 : Categorie_ODS.

- *Loc_gouvernorat_ODS.*

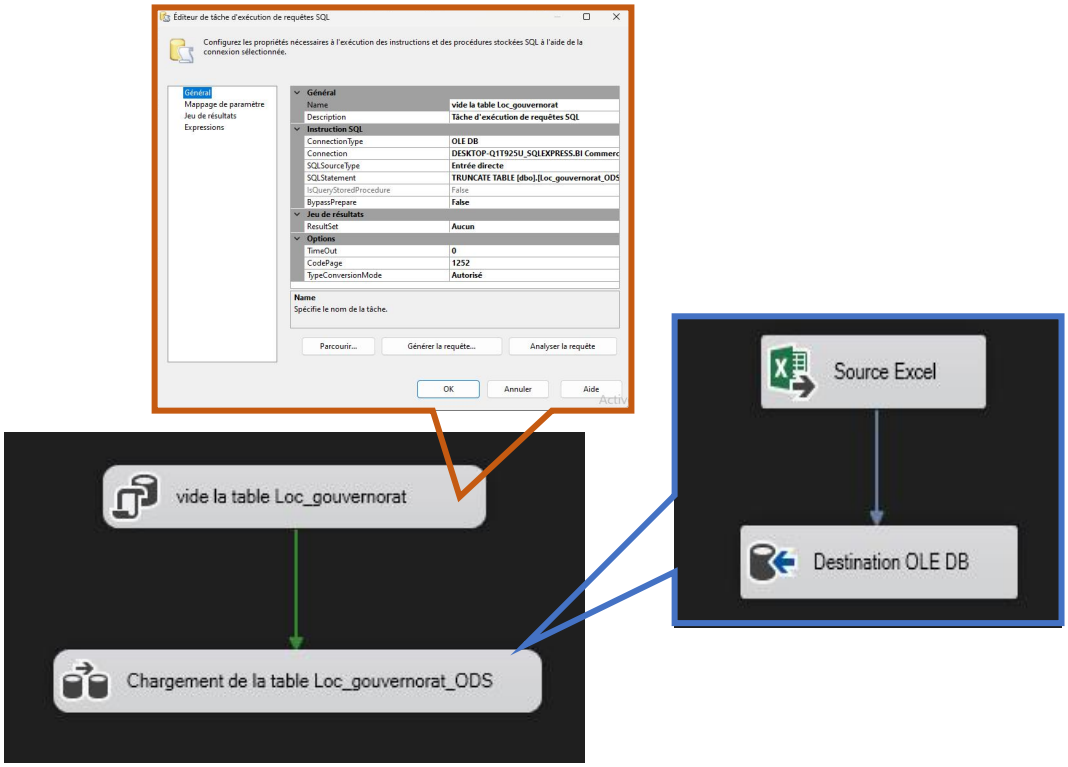

Figure 19 : Loc_gouvernorat_ODS.

III. Transformation et chargement des données

Dans cette partie on va concentrer sur les deux dernières étapes du processus ETL, la première étape est la transformation des données consiste à convertir des données d'un format à un autre. La transformation des données est utilisée dans la plupart des tâches d'intégration des données et de gestion des données, telles que le nettoyage des données/la préparation préalable des données et l'entreposage des données et finalement, les données transformées seront chargées dans l'entrepôt de données cible.

Pendant la phase de transformation et de chargement des données du processus ETL, nous allons Implémentez notre entrepôt de données depuis ODS. Nous fournissons d'abord la table de dimensions avant la table de faits pour éviter de violer les contraintes d'intégrité référentielle.

1. Alimentation des tables de dimensions

Pour faciliter la compréhension de cette tâche, nous avons créé un diagramme d'activité ce qui suit :

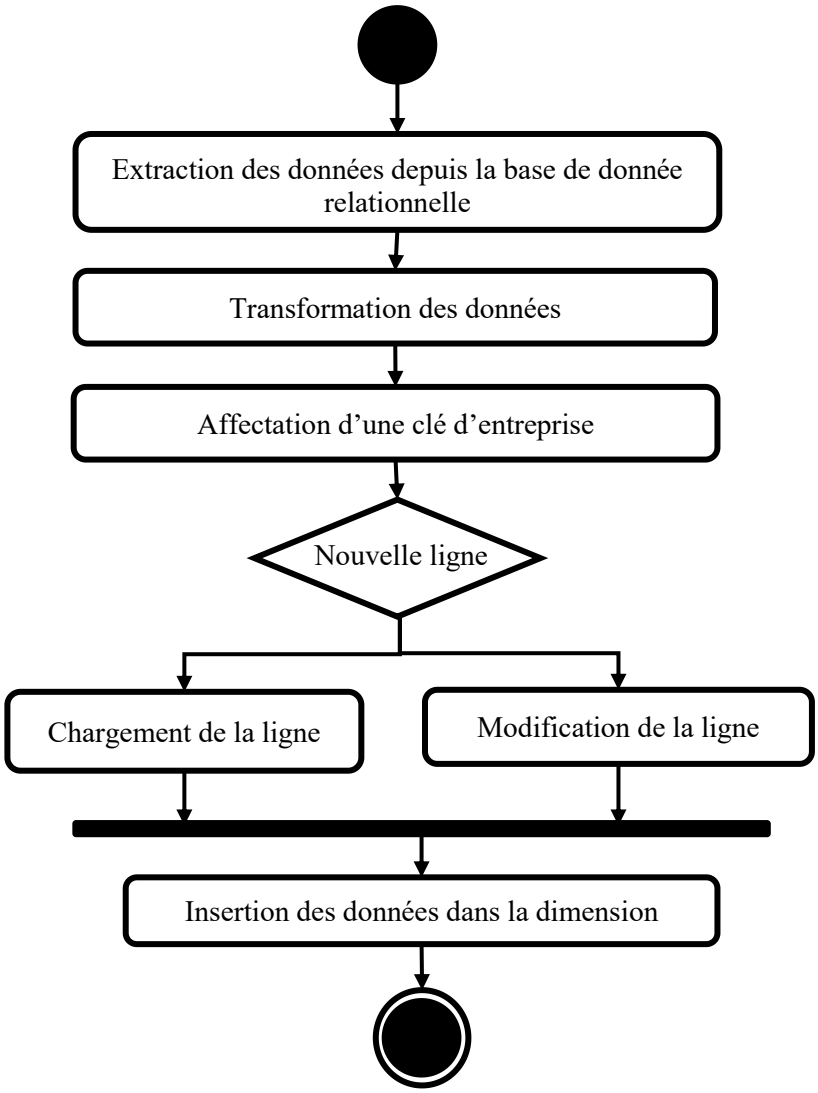

Figure 20 : Diagramme d'activité de chargement des dimensions.

Pour remplir chaque table de dimensions, nous extrayons d'abord les données brutes généré à partir de la table source Client_ODS de BI Commercial ODS. Nous effectuons ensuite les modifications en utilisant les composants de transformation des données et de colonnes dérivées pour garantir la standardisation et la cohérence des données. Enfin, grâce à l'utilisation de composants, de **recherche** et à l'aide des **requête SQL** nous pouvons charger les données avec succès.

Dimension a variation lente , est un élément qui nous permet d'effectuer des opérations de recherche. Recherchez en concaténant les données des colonnes d'entrée source aux colonnes de sortie.

On a créé une variable à travers la fonction "ROW COUNT" pour compter le nombre des lignes insérer dans la dimension, qui va nous aider à implémenter la table LOG_CHECK, pour bien vérifier l'insertion et la mise à jour des données dans les dimensions.

Les figures suivantes illustre l'alimentation des tables dimensions.

- **Dimension Client**

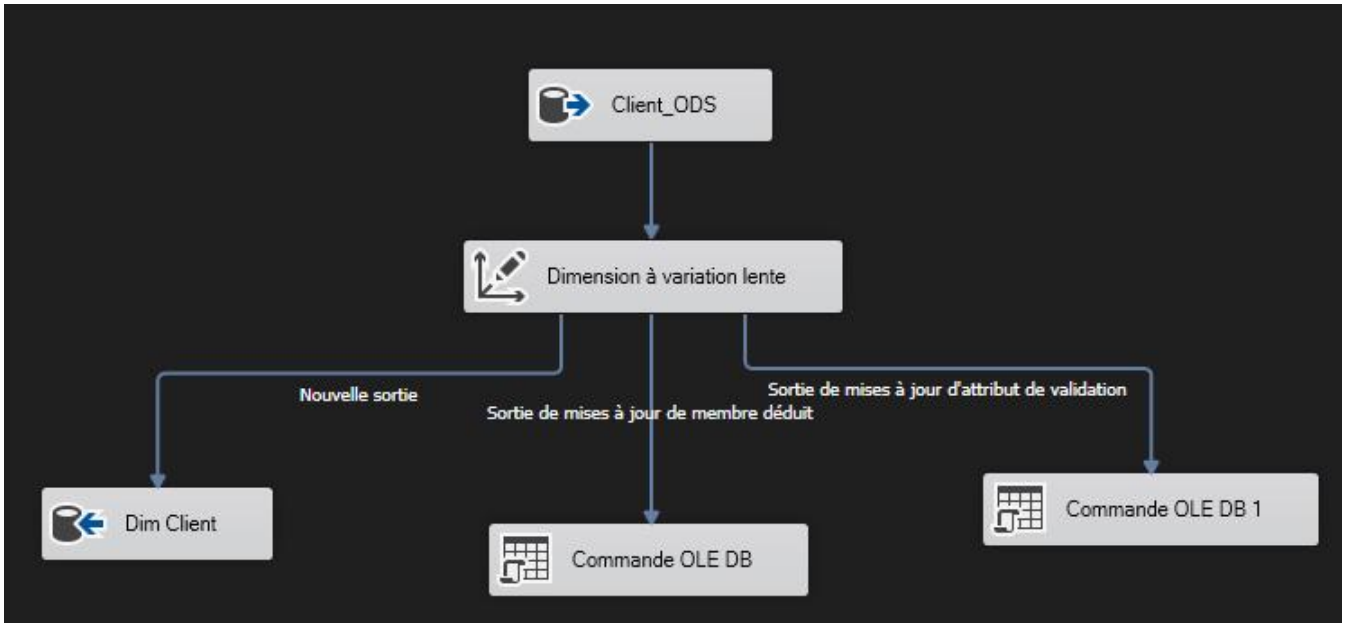

Figure 21 : Alimentation de la table DIM_Client.

- **Dimension Produit**

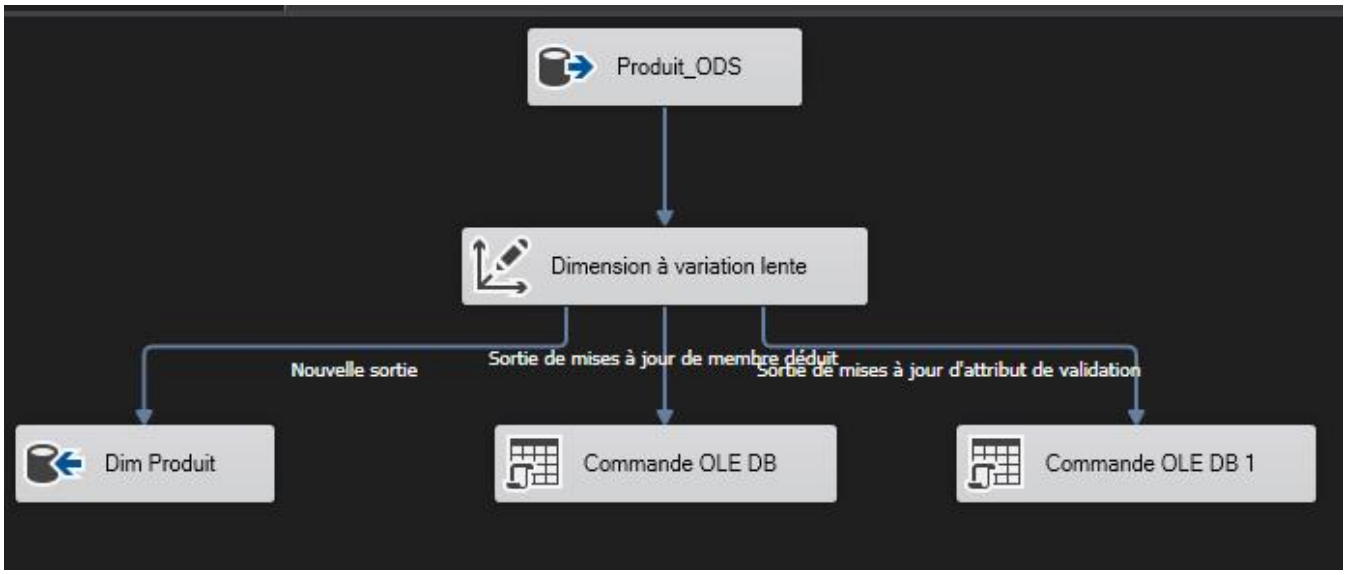

Figure 22 : Alimentation de la table DIM_PRODUIT.

- **Dimension Date**

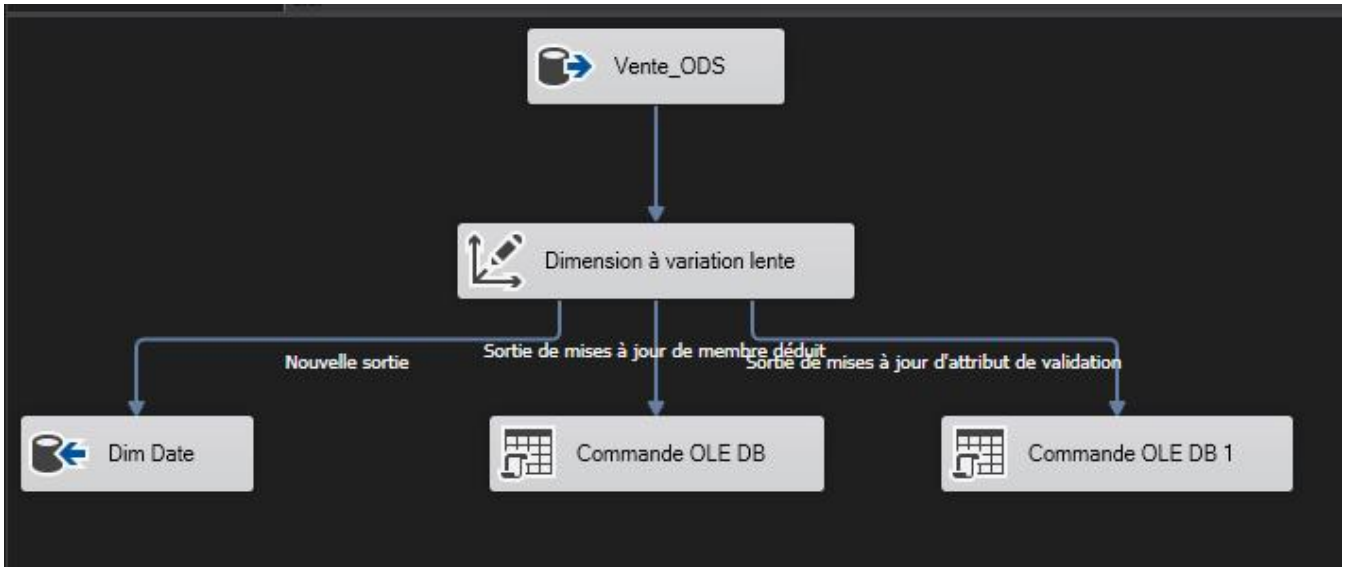

Figure 23 : Alimentation de la table DIM_CUSTOMER.

2. Alimentation de la table de fait

Après avoir alimenté les tables de dimension, nous décrivons dans ce qui suit les étapes de chargement de la table de fait. Dans le but de faciliter leurs compréhensions, nous présentons dans la figure 24 le diagramme d'activités d'alimentation de la table de fait.

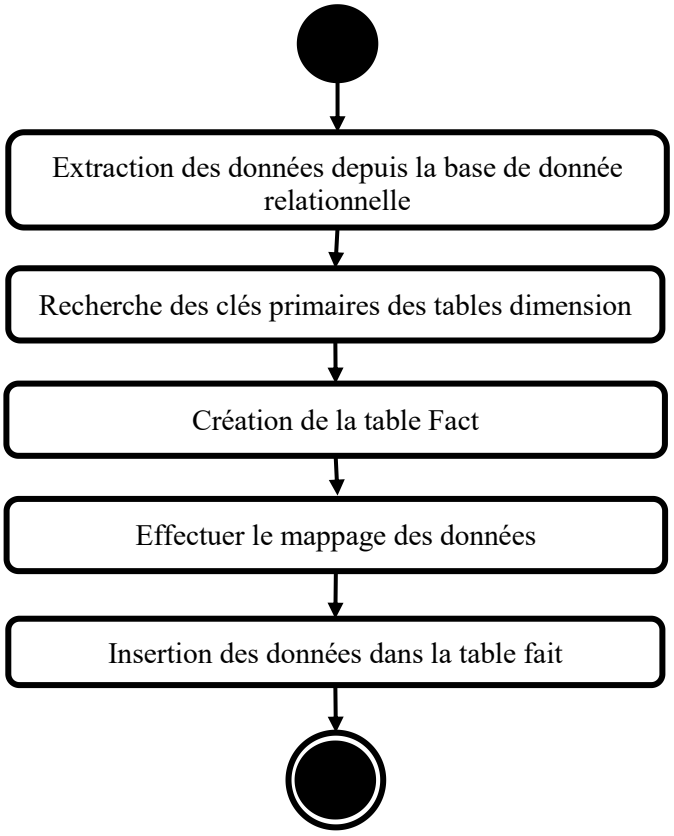

Figure 24 : Diagramme d'activité du chargement de la table de fait

La table FACT_Vente c'est la Vente_ODS pour obtenir les attributs nécessaires assurant le calcul des mesures et le mappage des données au niveau de la table de fait.

En fin de compte, nous résumons le développement de notre processus ETL par le flot de traitement décrivant l'alimentation de notre entrepôt de données DWH dans la figure 25.

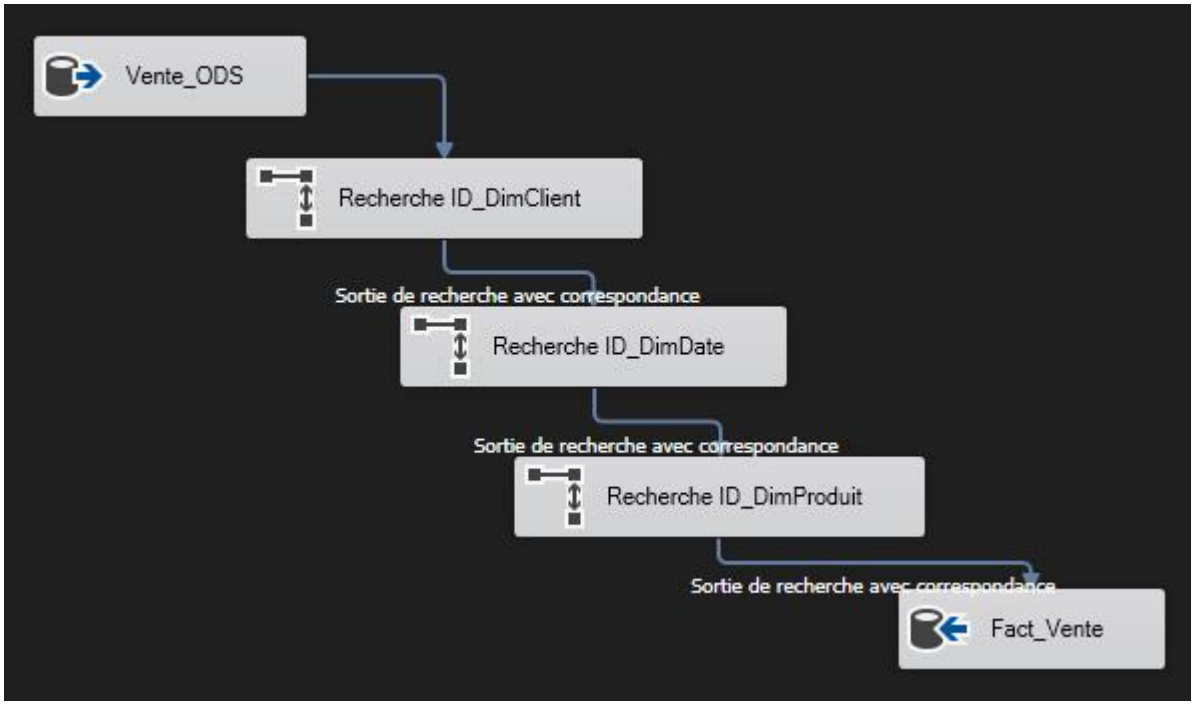

Figure 25 : Diagramme d'activité du chargement de la table de fait.

Partie2 : Solution BI

Page d'accueil

La page d'accueil de notre tableau de bord constitue un point d'entrée centralisé. Elle offre une interface intuitive permettant de naviguer facilement entre les différentes pages de reporting. Grâce à l'utilisation de boutons interactifs, chaque utilisateur peut accéder rapidement aux rapports spécifiques, tels que les ventes, la performance des produits,par data, par date, ou encore l'analyse géographique.

Figure 26 : Page d'accueil.

Reporting des Vente par Client :

Cette page du tableau de bord offre une analyse détaillée des ventes par client, ventilée par gouvernorat et par année. Elle permet d'identifier les clients les plus rentables (top 5), en croisant plusieurs dimensions telles que le type de client, le secteur d'activité et l'année de référence....

Figure 27 : Reporting des vente par client.

Reporting des Vente par Produit:

Cette page fournit une analyse approfondie des performances commerciales par produit, en mettant en évidence les articles les plus vendus. Elle présente le chiffre d'affaires et les quantités totales par catégorie de produit, avec la possibilité de filtrer les données par catégorie de produit et par année.

Figure 28 : Reporting des vente par Produit.

Reporting des Vente par Date:

Cette page propose une analyse temporelle des ventes, permettant de suivre l'évolution du chiffre d'affaires au fil du temps(annee et mois) et de détecter les tendances saisonnières ou les variations liées à des événements spécifiques.

Figure 29 : Reporting des vente par date.

En perspective, l'intégration de modèles prédictifs permettrait d'anticiper les ventes futures et d'optimiser la stratégie commerciale.